

Système de recommandation pour produits de beauté AMAZON

Auteur :

Mounir AMANOUS, Salim LAKHAL

Date :

27 novembre 2025

Table des matières

1	INTRODUCTION ET CONTEXTE	2
2	APPROCHE 1 : FILTRAGE COLLABORATIF (USER-BASED)	2
2.1	Concept Théorique	2
2.2	Implémentation	2
2.2.1	Création d'utilisateurs virtuels	2
2.2.2	Construction de la matrice utilisateur-produit	3
2.2.3	Similarité entre utilisateurs	3
2.2.4	Recommandation collaborative	3
2.3	Résultats	3
3	APPROCHE 2 : FILTRAGE BASÉ SUR LE CONTENU	3
3.1	Concept Théorique	3
3.2	Implémentation	4
3.2.1	Vectorisation TF-IDF	4
3.2.2	Similarité cosinus entre produits	4
3.2.3	Recommandation	4
3.3	Prédiction de ratings	4
3.4	Résultats	4
4	COMPARAISON DES DEUX APPROCHES	4
4.1	Synthèse	5
	CONCLUSION GÉNÉRALE	5

1 INTRODUCTION ET CONTEXTE

Dataset utilisé : Produits de beauté Amazon

- Nombre initial de produits : 112 590
- Catégories : All Beauty (97.5%), Premium Beauty (2.5%)
- Features disponibles : titre, description, features, rating moyen, nombre de avis
- Rating moyen global : 3.99/5

Prétraitement appliqué :

1. Suppression des produits sans notes
2. Filtrage pour garder uniquement les produits avec ≥ 10 avis
3. Sélection aléatoire de 200 produits

Objectifs :

- Garantir la qualité statistique des ratings
- Réduire la dimensionnalité
- Travailler avec un dataset équilibré

2 APPROCHE 1 : FILTRAGE COLLABORATIF (USER-BASED)

2.1 Concept Théorique

Le Filtrage Collaboratif repose sur l'idée que :

« Les utilisateurs ayant aimé les mêmes produits par le passé aimeront probablement les mêmes produits à l'avenir. »

Principe :

1. Construire une matrice Utilisateur $\times$ Produit
2. Calculer la similarité entre utilisateurs
3. Prédire les ratings manquants grâce aux utilisateurs similaires

2.2 Implémentation

2.2.1 Création d'utilisateurs virtuels

- 5 niveaux de satisfaction : Très satisfait $\rightarrow$ Insatisfait
- 2 catégories : All Beauty et Premium Beauty
- Total : 10 utilisateurs virtuels

2.2.2 Construction de la matrice utilisateur-produit

La matrice 10×200 est remplie selon :

- Les produits correspondant au niveau de satisfaction reçoivent leur rating réel
- Les produits d'autres catégories mais très bien notés reçoivent un rating pondéré (70%)

2.2.3 Similarité entre utilisateurs

Mesure : similarité cosinus

$$\text{sim}(u_1, u_2) = \frac{u_1 \cdot u_2}{\|u_1\| \|u_2\|}$$

2.2.4 Recommandation collaborative

Principe :

- Trouver les utilisateurs similaires
- Pour chaque produit non noté : moyenne pondérée des ratings des voisins

Code Python implémentant la logique décrite ci-dessus.

2.3 Résultats

- MAE = 0.8380
- RMSE = 0.9862

Interprétation :

- Erreur élevée sur une échelle 1–5
- Les utilisateurs artificiels limitent la précision

3 APPROCHE 2 : FILTRAGE BASÉ SUR LE CONTENU

3.1 Concept Théorique

Principe :

« Si un utilisateur aime un produit, il aimera probablement les produits similaires. »

Étapes :

1. Construire un texte combiné (titre + features + description)
2. Vectoriser avec TF-IDF
3. Calculer la similarité cosinus
4. Recommander les produits les plus proches

3.2 Implémentation

3.2.1 Vectorisation TF-IDF

- Matrice : 200×100
- Mots rares favorisés par l’IDF

3.2.2 Similarité cosinus entre produits

Deux produits sont similaires s’ils partagent :

- les mêmes termes caractéristiques
- un usage proche (ex : “brush”)
- des matières ou catégories similaires

3.2.3 Recommandation

- Trier par similarité décroissante
- Exclure le produit lui-même
- Retourner les N plus similaires

Code Python implémentant la logique décrite ci-dessus.

3.3 Prédiction de ratings

Principe :

- Trouver les produits similaires déjà notés par l’utilisateur
- Calculer une moyenne pondérée

3.4 Résultats

- $MAE = 0.1992$
- $RMSE = 0.3107$

Interprétation :

- Très haute précision
- $4\times$ meilleur que le filtrage collaboratif

4 COMPARAISON DES DEUX APPROCHES

Tableau comparatif

Critère	Collaboratif	Contenu	Gagnant
MAE	0.8380	0.1992	Contenu

RMSE	0.9862	0.3107	Contenu
Facilité d'implémentation	Moyen	Facile	Contenu
Données utilisateur requises	Oui	Non	Contenu
Cross-catégories	Oui	Non	Collaboratif
Découverte	Bonne	Limitée	Collaboratif
Interprétabilité	Moyenne	Excellente	Contenu
Scalabilité	Limitée	Très bonne	Contenu

4.1 Synthèse

Filtrage Collaboratif

- + Découverte de nouveaux produits
- + Recommandations inter-catégories
- – Mauvaise performance sur ce dataset

Filtrage Contenu

- + Très bon MAE/RMSE
- + Interprétable et robuste
- – Recommandations parfois trop similaires

Conclusion générale : Le filtrage contenu est largement supérieur sur ce dataset.

CONCLUSION GÉNÉRALE

Ce projet compare deux approches majeures :

1. **Filtrage Collaboratif** : basé sur la similarité entre utilisateurs
2. **Filtrage Basé Contenu** : basé sur la similarité entre produits

Résultat clé :

Le filtrage contenu est $4,2 \times$ plus précis que le filtrage collaboratif.

Une approche hybride serait optimale en production.